RAPPORT DE PROJET:

Prédiction du risque d'abandon scolaire

Réalisé par: KOFFI KOUAME JEAN-BAPTISTE

Numéro whatsapp: 0565728863

Enseignant: **Dr Kamagaté**

Introduction

L'abandon scolaire est un problème majeur aux impacts sociaux, économiques et éducatifs. Les étudiants concernés rencontrent souvent des difficultés d'insertion professionnelle. Pour y faire face, les établissements cherchent à identifier rapidement les étudiants en difficulté. Grâce à la science des données et à l'intelligence artificielle, il est aujourd'hui possible de développer des modèles prédictifs pour anticiper ces risques.

L'objectif de ce projet est de concevoir un modèle de machine learning permettant de prédire le risque d'abandon scolaire à partir de données académiques et comportementales. Ce modèle vise à fournir une aide à la décision pour les enseignants et les responsables pédagogiques.
Ainsi, nous disposons de données concernant 300 étudiants, avec 7 informations liées à leurs résultats scolaires et à leur comportement, présentées dans le tableau ci-dessous.

Variable	Type	Description	Valeurs possibles
`age`	numérique	Âge de l'étudiant	15 - 24 ans
`gender`	Catégorielle	Sexe	Male / Female
`average_grade`	numérique	Moyenne générale	5.03 - 17.96 (/20)
`absenteeism_rate`	numérique	Taux d'absentéisme	0.00 - 0.50 (0 à 50%)
`internet_access`	Catégorielle	Accès Internet à domicile	Yes / No
`study_time_hours`	numérique	Heures d'étude par jour	0.0 - 5.0 heures
`extra_activities`	Catégorielle	Activités extrascolaires	Yes / No

La variable cible `dropout_risk` qui est le **risque d'abandon scolaire**, codée comme suit :

- 0 : Étudiant sans risque
- 1 : Étudiant à risque

est construite selon une logique métier réaliste. Un étudiant est considéré à risque s'il remplit au moins deux des conditions suivantes :

- Moyenne inférieure à 10/20
- Absentéisme supérieur à 30%
- Temps d'étude inférieur à 1 heure par jour

Prétraitement et analyse exploratoire des données

Le prétraitement des données est une étape essentielle dans tout projet de machine learning. Il permet de transformer les données brutes en un format exploitable par les algorithmes.

- Aucune valeur manquante n'a été détectée
- Les variables catégorielles ont été encodées avec la méthode One-Hot Encoding

- Les variables numériques ont été normalisées à l'aide du StandardScaler

Ces transformations permettent d'obtenir un jeu de donnée homogène et optimisé pour l'apprentissage automatique.

L'analyse exploratoire nous a permis de comprendre la structure des données et d'identifier les variables les plus influentes. Ces variables présentent une corrélation significative avec le risque d'abandon scolaire

-**Le taux d'absentéisme (+0.41):** *Plus un élève est absent, plus il risque d'abandonner*

-La moyenne académique (-0.38): *Plus ses notes sont élevées, moins il risque d'abandonner*

-Le temps d'étude (-0.29): *Plus il consacre du temps aux études, moins il risque d'abandonner*

Donc, l'absentéisme augmente le risque, tandis que de bonnes notes et un temps d'étude élevé le réduisent.

Le prétraitement s'est poursuivi par une étape de **feature engineering**, consistant à créer de nouvelles variables afin d'évaluer leur pertinence et d'améliorer les performances du modèle.

Deux variables ont été construites :

- **Un ratio présence/absence** : il mesure le rapport entre le temps de présence et le temps d'absence. Plus sa valeur est élevée, plus l'étudiant est assidu.
- **Un score global de risque** : calculé à partir des trois principaux critères pédagogiques, il varie de 0 à 3 et représente un niveau global de risque d'abandon.

L'analyse de leur corrélation avec la variable cible a donné les résultats suivants:

- **(+0.82) pour le score global** : cette variable est très fortement liée à la cible. Cependant, son utilisation aurait entraîné une **fuite de données (data leakage)**, ce qui aurait artificiellement

amélioré les performances du modèle sans réelle capacité d'apprentissage.

- **(-0.20) pour le ratio présence/absence** : cette variable présente une faible importance et correspond à une transformation directe du taux d'absentéisme. Elle est donc **redondante**, car elle n'apporte pas d'information nouvelle au modèle.

Ainsi, ces variables ont été supprimées avant l'entraînement final afin de garantir un modèle **plus réaliste, fiable et généralisable**.

Par ailleurs, nous avons étudié si le **sexe** influence le risque d'abandon scolaire .

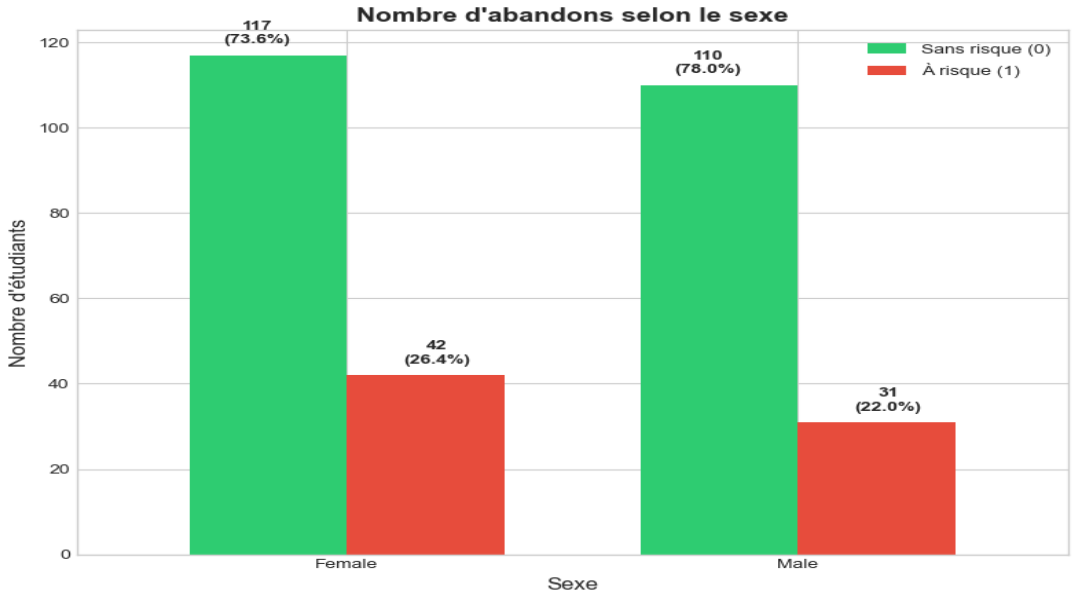

- Femmes : 42 sur 159 à risque (**26,4%**)
- Hommes : 31 sur 141 à risque (**22,0%**)

Conclusion :

La différence est faible, ce qui montre que le **sexe n'est pas un facteur déterminant du risque d'abandon scolaire**.

Modélisation

Plusieurs modèles de machine learning ont été testés afin de comparer leurs performances :

- Régression Logistique
- Random Forest
- Support Vector Machine (SVM)

Chaque modèle a été évalué à l'aide de métriques adaptées :

- Accuracy
- Precision
- Recall
- F1-score

Le modèle Random Forest s'est démarqué avec les meilleures performances globales.

```
                Modele  Accuracy  Precision  Recall  F1-score
0  Logistic Regression     0.867      0.733   0.733     0.733
1        Random Forest     0.983      1.000   0.933     0.966
2                  SVM     0.883      0.833   0.667     0.741
==============================================

Validation croisée (5-fold) :
Logistic Regression: F1 moyen = 0.763
Random Forest: F1 moyen = 0.947
SVM: F1 moyen = 0.748
==============================================
MATRICES DE CONFUSION DES 3 MODÈLES DE BASE
```

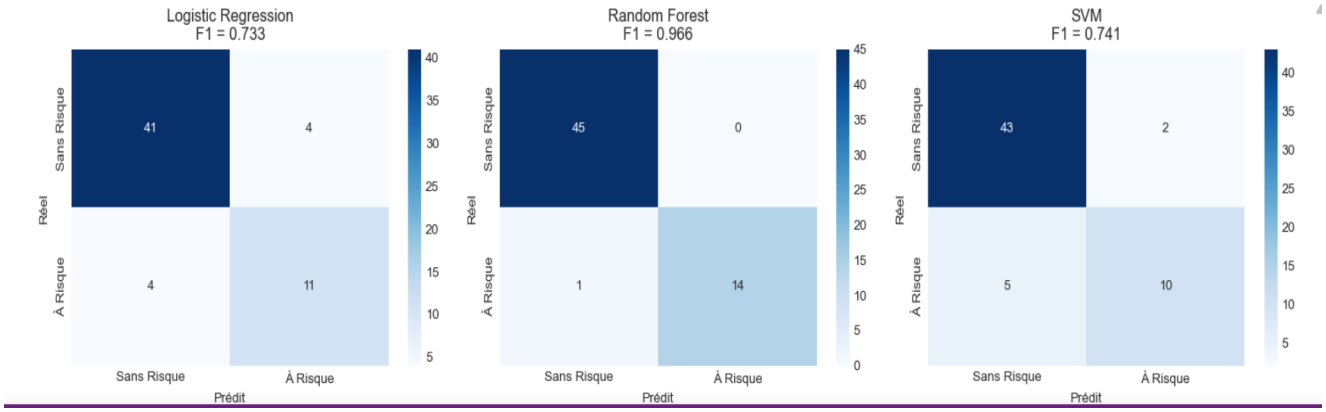

NB: Le jeu de données présente un **déséquilibre modéré** entre les deux classes

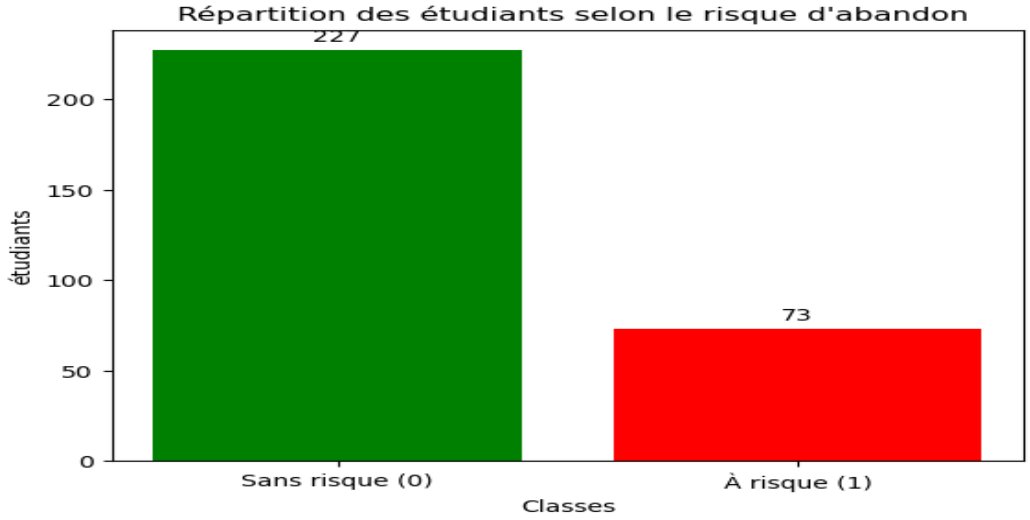

Cependant,On a privilégié des métriques comme le **F1-score** plutôt que la simple précision globale(accuracy).

Une phase d'optimisation a été réalisée à l'aide de la méthode GridSearch sur le modèle Random Forest.
Cette technique permet de tester différentes combinaisons de paramètres afin d'améliorer les performances du modèle.

Après optimisation, le modèle obtient d'excellents résultats :

- Il identifie correctement **14 étudiants à risque sur 15**.
- Il **ne signale jamais à tort** un étudiant qui va bien (aucune fausse alerte).
- Sa fiabilité globale est de **98,3%**.

Autrement dit, quand le modèle dit "À Risque", on peut avoir confiance : l'étudiant a vraiment besoin d'un suivi.

Conclusion

Ce projet a permis de développer un modèle prédictif performant pour le risque d'abandon scolaire.
Le modèle a été intégré dans une **application web** (Flask), offrant aux équipes pédagogiques un outil simple et rapide pour anticiper les décrochages et mettre en place des actions de soutien ciblées.

Présentation de l'application

L'application a été développée en utilisant le **meilleur modèle de prédiction sélectionné**, ainsi que les mêmes étapes de **prétraitement des données (data preprocessing)** appliquées lors de l'entraînement.

Le fonctionnement est le suivant :

L'utilisateur remplit un formulaire contenant les différentes variables utilisées par le modèle. Ces données sont ensuite traitées et analysées par le modèle, qui génère une **prédiction du risque d'abandon scolaire**, accompagnée d'un **pourcentage de confiance**.

En fonction du résultat obtenu et des valeurs saisies, l'application fournit également des **recommandations personnalisées** afin d'aider à réduire le risque identifié.

Lien de l'appli : JB Études - Prédiction Risque d'Abandon

- Risque élévé

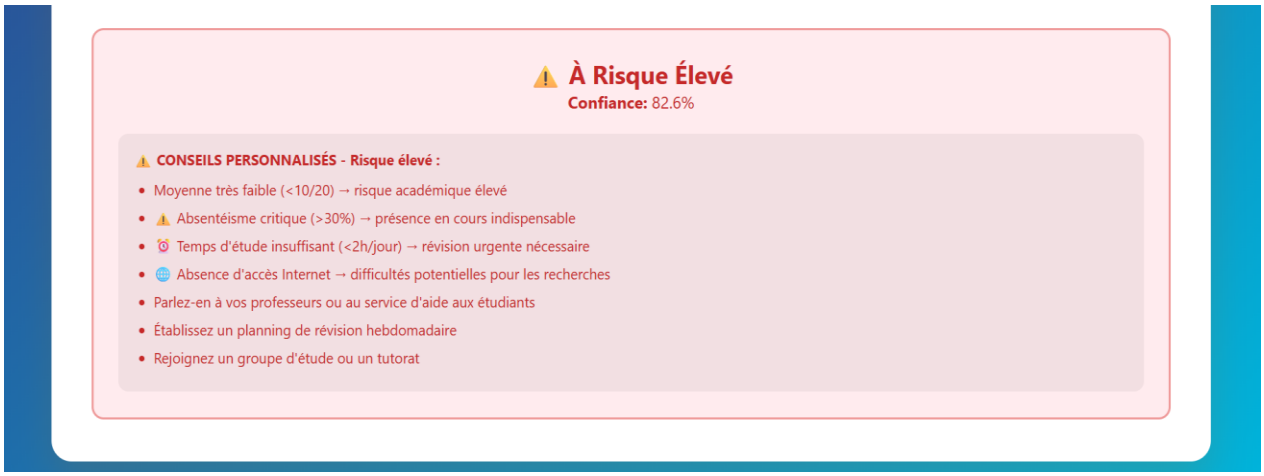

-Faible risque